Тимофеев Кирилл Юрьевич

Junior ML/LLM Engineer

Москва hash0xcb8c@yandex.ru +7 (926) 505-48-29 github.com/laxier

О СЕБЕ

Junior ML/LLM Engineer / Backend-разработчик, коммерческий опыт с 2023 года. Пишу сервисы на Python (FastAPI, Django/DRF, SQLAlchemy, Docker) и строю вокруг них LLM-агентов: проектирую агентные циклы на Claude API, MCP-серверы с авторизацией OAuth 2.1, настраиваю стриминг ответов по SSE.
Поведение языковых моделей контролирую инженерными методами: валидацией данных, structured output, переносом расчётов в код, логированием ошибок и оценкой качества через LLM-as-a-judge с передачей спорных случаев человеку. Имею опыт командной разработки, создания инструментов для автоматизации B2B-закупок и запуска веб-сервисов с нуля в продакшн. Использую рабочий китайский язык (B1) для разбора документов и карточек товаров на Taobao и Pinduoduo.

Backend: Python, FastAPI, Django/DRF, REST API, SQLAlchemy, Alembic, SQL, SQLite, Docker, Git, pytest, asyncio.
LLM Engineering: tool use, structured output, мультимодальные запросы, стриминг через SSE, extended thinking, MCP-серверы (FastMCP, OAuth 2.1), RAG (LangChain, Chroma, pgvector), LLM-as-a-judge / LLM eval.
Classical ML & Data: PyTorch, PyTorch Lightning, scikit-learn, CatBoost, LightGBM, XGBoost, Optuna, Hugging Face Transformers, PySpark, Pandas, PostgreSQL, A/B-тесты.
Языки: английский B2, китайский B1.

ОПЫТ РАБОТЫ

Junior ML/LLM Engineer, Умный трекер питания 12.2025 – 04.2026
Команда из 5 человек. Telegram-бот на ~1000 пользователей и iOS-приложение

- Спроектировал агентный цикл на Claude API (tool_use → tool_result) с лимитом шагов (до 5–7 итераций), возвратом ошибок инструментов модели и стримингом ответов по SSE. Сократил задержку первого токена (TTFT) до 400–600 мс.
- Реализовал MCP-сервер на 75 инструментов с авторизацией OAuth 2.1 (FastMCP, FastAPI, Streamable HTTP) для подключения внешних ИИ-агентов.
- Снизил количество ошибок в ответах модели с 12% до 0.5% с помощью каскадного поиска данных, валидации Structured Output через Pydantic v2 и переноса математических расчётов в Python-код.
- Настроил мультимодальное распознавание блюд, продуктовых этикеток и бланков анализов по фото с приведением извлеченных данных к единому структурированному формату.
- Выстроил отладку промптов по логам: разбирал реальные диалоги и сбои агента в продакшене, правил системный промпт и спецификации инструментов. Доля неверных вызовов (tool call errors) снизилась с 18% до 3%.
- Написал бэкенд сервиса: разработал архитектуру на FastAPI и SQLAlchemy, настроил миграции через Alembic и упаковал приложение в Docker.

Стек: Python, FastAPI, SQLAlchemy, Alembic, Claude API, MCP, Pydantic v2, Docker, SSE, OAuth 2.1, Telegram Bot API.

Python-разработчик / AI Engineer, Автоматизация закупок из Китая 11.2025 – 12.2025
Заказная разработка под байера, работал один. Инструменты для закупок на Taobao и Pinduoduo с карго-доставкой в РФ

- Разработал локальный прокси-сервис на FastAPI, который через Claude API генерирует товарные описания для таможенных документов в реальном времени.
- Спроектировал LLM-пайплайн со структурированным выводом (Structured Output) для сборки сопроводительной документации по строгим правилам.
- Внедрил автоматическую оценку качества ответов по схеме LLM-as-a-judge (верификация второй моделью) с автоматическим фолбеком на ручную проверку человеком в спорных случаях.
- Написал клиентские скрипты на JavaScript (Tampermonkey) для встраивания разработанного API прямо в веб-интерфейсы китайских маркетплейсов.
- Ускорил подготовку документов байера: время обработки одной позиции снизилось с ~1.5 минут до ~20 секунд. Сэкономил заказчику около 13 часов ручного ввода на партии из 700 позиций (30 отправлений).

Стек: Python, FastAPI, JavaScript (Tampermonkey), Claude API, REST API, Structured Output, LLM-as-a-judge.

Data Analyst / ETL / Junior ML, Самолет Плюс 03.2023 – 08.2023
Стажировка, аналитика сделок сети агентств недвижимости

- Разработал витрины данных на SQL (PostgreSQL) для продуктовой аналитики: считал активность пользователей, конверсии воронки продаж и метрики удержания (retention).
- Построил ETL-процессы на PySpark и Python: собирал, очищал и объединял разрозненные данные из разных источников в единые датасеты для аналитики и ML-моделей.

- Проводил A/B-тестирование: рассчитывал размеры выборок, проверял статистические гипотезы, сравнивал группы и готовил выводы для продуктовой команды.

Стек: Python, SQL, Pandas, NumPy, PostgreSQL, PySpark, ETL.

🎓 ОБРАЗОВАНИЕ

Бакалавриат 01.03.02 Прикладная математика и информатика 2023 – 2027 | Москва
Финансовый Университет при правительстве РФ
Очная форма. Профиль: Прикладное машинное обучение

🗁 ПРОЕКТЫ

汉语中心 — платформа для изучения китайского 2024 – по настоящее время
Python, Django, DRF, OAuth 2.1, MCP · laxier.github.io/hanyu
Работаю над ним с 2024 года.

- Перенёс бэкенд проекта с Flask на Django/DRF для повышения стабильности и масштабируемости системы; спроектировал архитектуру из 8 изолированных модулей (~350 коммитов).
- Разработал MCP-сервер на 38 инструментов (управление колодами, уроками, расписанием), интегрировав его с Django через Streamable HTTP / JSON-RPC для прямого управления функциями из чата с моделью.
- Реализовал алгоритм интервального повторения слов SM-2: настроил расчёт времени возврата карточек ученику и вывод аналитики прогресса.
- Настроил безопасность подключений по OAuth 2.1 (с поддержкой PKCE и динамической регистрацией клиентов), исключив передачу прямых паролей ИИ-репетитору.
- Покрыл бэкенд REST API OpenAPI-документацией и настроил автоматический деплой проекта на облачную платформу Amvera.
- Разрабатываю систему автоматического тестирования LLM eval для мониторинга и численной оценки качества ответов ИИ-педагога.

Стек: Python, Django, DRF, Flask, Claude API, MCP, JSON-RPC, OAuth 2.1 (PKCE), OpenAPI, алгоритм SM-2, Amvera.