Тимофеев Кирилл Юрьевич

+7 (926) 505-48-29
hash0xcb8c@yandex.ru
github.com/laxier

Мужчина, 22 года, родился 27 ноября 2003

Проживает: Москва

Гражданство: Россия, есть разрешение на работу: Россия

Не готов к переезду, не готов к командировкам

Желаемая должность и зарплата

ML-инженер

Специализации: BI-аналитик, аналитик данных; Дата-сайентист; Программист, разработчик

Тип занятости: полная занятость

Формат работы: на месте работодателя

Опыт работы

Декабрь 2025 — Апрель 2026

5 месяцев

Умный трекер питания — Junior ML/LLM Engineer

Команда из 5 человек. Telegram-бот на ~1000 пользователей и iOS-приложение

- Спроектировал агентный цикл на Claude API (tool_use → tool_result) с лимитом шагов (до 5–7 итераций), возвратом ошибок инструментов модели и стримингом ответов по SSE. Сократил задержку первого токена (TTFT) до 400–600 мс.
- Реализовал MCP-сервер на 75 инструментов с авторизацией OAuth 2.1 (FastMCP, FastAPI, Streamable HTTP) для подключения внешних ИИ-агентов.
- Снизил количество ошибок в ответах модели с 12% до 0.5% с помощью каскадного поиска данных, валидации Structured Output через Pydantic v2 и переноса математических расчётов в Python-код.
- Настроил мультимодальное распознавание блюд, продуктовых этикеток и бланков анализов по фото с приведением извлеченных данных к единому структурированному формату.
- Выстроил отладку промптов по логам: разбирал реальные диалоги и сбои агента в продакшене, правил системный промпт и спецификации инструментов. Доля неверных вызовов (tool call errors) снизилась с 18% до 3%.
- Написал бэкенд сервиса: разработал архитектуру на FastAPI и SQLAlchemy, настроил миграции через Alembic и упаковал приложение в Docker.

Стек: Python, FastAPI, SQLAlchemy, Alembic, Claude API, MCP, Pydantic v2, Docker, SSE, OAuth 2.1.

Ноябрь 2025 — Декабрь 2025

2 месяца

Автоматизация закупок из Китая — Python-разработчик / AI Engineer

Заказная разработка под байера, инструменты для Taobao и Pinduoduo

- Разработал локальный прокси-сервис на FastAPI, который через Claude API генерирует товарные описания для таможенных документов в реальном времени.
- Спроектировал LLM-пайплайн со структурированным выводом (Structured Output) для сборки сопроводительной документации по строгим правилам.
- Внедрил автоматическую оценку качества ответов по схеме LLM-as-a-judge (верификация второй моделью) с автоматическим фолбеком на ручную проверку человеком в спорных случаях.
- Написал клиентские скрипты на JavaScript (Tampermonkey) для встраивания разработанного API прямо в веб-интерфейсы китайских маркетплейсов.
- Ускорил подготовку документов байера: время обработки одной позиции снизилось с ~1.5 минут до ~20 секунд. Сэкономил заказчику около 13 часов ручного ввода на партии из 700 позиций (30 отправлений).

Стек: Python, FastAPI, JavaScript, Claude API, REST API, Structured Output.

Март 2023 — Август 2023

6 месяцев

Стажер — Data Analyst / ML Engineer

Компания: Самолет Плюс

- **Продуктовая аналитика:** Разработал и оптимизировал витрины данных на базе SQL и PostgreSQL для сквозной аналитики сделок сети агентств недвижимости.
- **Расчет метрик:** Реализовал расчет ключевых продуктовых метрик, включая активность пользователей (DAU/MAU), конверсии на этапах воронки продаж и показатели удержания клиентов (Retention Rate).
- **Инженерия данных (ETL):** Построил отказоустойчивые ETL-процессы с использованием PySpark и Python для сбора, очистки и агрегации разрозненных данных из различных источников в единые аналитические датасеты.
- **Подготовка данных для ML:** Сформировал структурированные наборы данных (датасеты) для последующего обучения моделей машинного обучения (Machine Learning).
- **A/B-тестирование:** Проводил статистический анализ в рамках A/B-тестов, рассчитывал необходимый размер выборок, проверял статистические гипотезы и презентовал продуктовые инсайты команде.

Технологический стек: Python, SQL, PostgreSQL, PySpark, ETL, Pandas, NumPy, A/B-testing, Продуктовые метрики.

2024 — по настоящее время

Пет-проект

汉语中心 — платформа для изучения китайского

laxier.github.io/hanyu

- Перенёс бэкенд проекта с Flask на Django/DRF для повышения стабильности и масштабируемости системы; спроектировал архитектуру из 8 изолированных модулей (~350 коммитов).
- Разработал MCP-сервер на 38 инструментов (управление колодами, уроками, расписанием), интегрировав его с Django через Streamable HTTP / JSON-RPC для прямого управления функциями из чата с моделью.
- Реализовал алгоритм интервального повторения слов SM-2: настроил расчёт времени возврата карточек ученику и вывод аналитики прогресса.
- Настроил безопасность подключений по OAuth 2.1 (с поддержкой PKCE и динамической регистрацией клиентов), исключив передачу прямых паролей ИИ-репетитору.
- Покрыл бэкенд REST API OpenAPI-документацией и настроил автоматический деплой проекта на облачную платформу Amvera.
- Разрабатываю систему автоматического тестирования LLM eval для мониторинга и численной оценки качества ответов ИИ-педагога.
- Плеер 字幕台 для изучения по видео: субтитры по словам, словарь по клику, отправка слов в колоду платформы.

Стек: Python, Django, DRF, Claude API, MCP, JSON-RPC, OAuth 2.1, OpenAPI, SM-2, Amvera.

2026 — по настоящее время

Пет-проект / диплом

Дипломный / Пет-проект: Извлечение атрибутов товаров с помощью квантованных LLM

Роль: Machine Learning Engineer / Разработчик (Исследования и Разработка)

- **Основная задача:** Разрабатываю сквозной NLP-конвейер для дипломного проекта по извлечению характеристик и спецификаций мониторов из русскоязычных описаний товаров.
- **Проектирование pipeline:** Спроектировал конвейер данных с применением подходов few-shot prompting и ограниченной генерации по JSON-схеме для получения детерминированных ответов.
- **Адаптация моделей:** Провожу тонкую настройку (fine-tuning) и адаптацию языковых моделей методами QLoRA и LoRA с целью оптимизации весов под доменную задачу.
- **Исследовательская работа:** Анализирую ложноположительные срабатывания (false-positive) моделей и оцениваю возможности кросс-доменного переноса (cross-domain transfer).
- **Инженерия данных:** Занимаюсь подготовкой и генерацией синтетических наборов данных с использованием подходов SynthIE для последующего обучения.

Технологический стек: Python, PyTorch, Transformers, bitsandbytes, 4-bit NF4, QLoRA, LoRA, XGrammar, JSON Schema, SynthIE.

Проекты

2024 — 2025

Пет-проект

Пет-проект: Детекция объектов на аэроснимках

Роль: Computer Vision (CV) Engineer / Разработчик

- **Основная задача:** Спроектировал и реализовал систему распознавания объектов на аэрофотоснимках с использованием алгоритмов компьютерного зрения.
- **Обучение моделей:** Провел предобработку датасета, настроил окружение и обучил сверточные нейросети семейств YOLOv5 и YOLOv8 с использованием аппаратного ускорения CUDA.
- **Валидация и анализ:** Сравнил обученные модели по ключевым метрикам компьютерного зрения (mAP, Precision, Recall) на валидационной выборке и выбрал наиболее эффективную архитектуру.

Технологический стек: Python, PyTorch, Ultralytics YOLO, Computer Vision, CUDA.

Образование

2023 — 2027
Неоконченное высшее

Финансовый университет при Правительстве Российской Федерации, Москва

Прикладная математика и информатика, профиль «Прикладное машинное обучение».

Повышение квалификации, курсы

2027

Инженер по глубокому обучению нейросетей: NLP и аудиоречевые технологии

Яндекс Практикум

Навыки

Знание языков

Русский — родной
Английский — B2 — Средне-продвинутый
Китайский — B1 — Средний

Навыки

Python SQL PostgreSQL FastAPI Django Django Rest Framework REST API SQLAlchemy Alembic asyncio Pytest Docker Git LLM RAG LangChain Chroma pgvector MCP FastMCP OAuth 2.1 NLP PyTorch PyTorch Lightning Hugging Face Transformers scikit-learn CatBoost LightGBM XGBoost Optuna Pandas NumPy PySpark A/B-тесты MLflow Airflow tool use structured output SSE extended thinking bitsandbytes QLoRA LoRA XGrammar JSON Schema SynthIE

Дополнительная информация

Обо мне

Junior ML/LLM Engineer / Backend-разработчик, коммерческий опыт с 2023 года. Пишу сервисы на Python (FastAPI, Django/DRF, SQLAlchemy, Docker) и строю вокруг них LLM-агентов: проектирую агентные циклы на Claude API, MCP-серверы с авторизацией OAuth 2.1, настраиваю стриминг ответов по SSE.

Поведение языковых моделей контролирую инженерными методами: валидацией данных, structured output, переносом расчётов в код, логированием ошибок и оценкой качества через LLM-as-a-judge с передачей спорных случаев человеку. Имею опыт командной разработки, создания инструментов для автоматизации B2B-закупок и запуска веб-сервисов с нуля в продакшн. Использую рабочий китайский язык (B1) для разбора документов и карточек товаров на Taobao и Pinduoduo.

Backend: Python, FastAPI, Django/DRF, REST API, SQLAlchemy, Alembic, SQL, SQLite, Docker, Git, pytest, asyncio.
LLM Engineering: tool use, structured output, мультимодальные запросы, стриминг через SSE, extended thinking, MCP-серверы (FastMCP, OAuth 2.1), RAG (LangChain, Chroma, pgvector), LLM-as-a-judge / LLM eval.

Classical ML & Data: PyTorch, PyTorch Lightning, scikit-learn, CatBoost, LightGBM, XGBoost, Optuna, Hugging Face Transformers, PySpark, Pandas, PostgreSQL, MLflow, Airflow, A/B-тесты.
Diploma / LLM Research: quantized LLM, 4-bit NF4, QLoRA, LoRA, bitsandbytes, XGrammar, JSON Schema, constrained decoding, SynthIE, micro-F1 / macro-F1, bootstrap-анализ.