Тимофеев Кирилл Юрьевич

Python Backend / AI Engineer

Москва · +7 (926) 505-48-29 · hash0xcb8c@yandex.ru · Telegram: @k_timofeev7 · github.com/laxier

О СЕБЕ

Backend (Python) / AI Engineer, коммерческий опыт с 2023 года. Пишу сервисы на Python (FastAPI, Django/DRF, SQLAlchemy, Docker) и строю вокруг них LLM-агентов: проектирую агентные циклы на Claude API, MCP-серверы с авторизацией OAuth 2.1, настраиваю стриминг ответов по SSE.

Поведение языковых моделей контролирую инженерными методами: валидацией данных, structured output, переносом расчётов в код, логированием ошибок и оценкой качества через LLM-as-a-judge с передачей спорных случаев человеку. Имею опыт командной разработки, создания инструментов для автоматизации закупок и запуска веб-сервисов с нуля в продакшн. Китайский (B1) использую в работе: разбираю документы и карточки товаров на Taobao и Pinduoduo.

НАВЫКИ

Backend: Python, FastAPI, Django/DRF, REST API, SQLAlchemy, Alembic, SQL, SQLite, Docker, Git, pytest, asyncio

LLM Engineering: tool use, structured output, мультимодальные запросы, стриминг через SSE, extended thinking, MCP-серверы (FastMCP, OAuth 2.1), RAG (LangChain, Chroma, pgvector), LLM-as-a-judge / LLM eval

Classical ML & Data: PyTorch, PyTorch Lightning, scikit-learn, CatBoost, LightGBM, XGBoost, Optuna, Hugging Face Transformers, PySpark, Pandas, PostgreSQL, A/B-тесты

Языки: английский B2, китайский B1

ОПЫТ РАБОТЫ

LLM-инженер · Smart Nutrition Tracker — 12.2025 – 04.2026

Команда из 5 человек. Telegram-бот на ~1 000 пользователей и iOS-приложение.

- Спроектировал агентный цикл на Claude API (tool_use → tool_result) с лимитом шагов (до 5–7 итераций), возвратом ошибок инструментов модели и стримингом ответов по SSE. Сократил задержку первого токена (TTFT) до 400–600 мс.
- Реализовал MCP-сервер на 75 инструментов с авторизацией OAuth 2.1 (FastMCP, FastAPI, Streamable HTTP) для подключения внешних ИИ-агентов.
- Снизил долю ошибок в ответах модели с 12% до 0,5%: каскадный поиск данных, валидация structured output через Pydantic, математические расчёты перенесены в Python-код.
- Настроил мультимодальное распознавание блюд, продуктовых этикеток и бланков анализов по фото с приведением извлечённых данных к единому структурированному формату.
- Выстроил отладку промптов по логам: разбирал реальные диалоги и сбои агента в продакшене, правил системный промпт и описания инструментов. Доля неверных вызовов инструментов снизилась с 18% до 3%.
- Написал бэкенд сервиса на FastAPI и SQLAlchemy, настроил миграции через Alembic и упаковал приложение в Docker.

Python, FastAPI, SQLAlchemy, Alembic, Claude API, MCP, Pydantic, Docker, SSE, OAuth 2.1, Telegram Bot API

Python-разработчик / AI Engineer · Автоматизация закупок из Китая 11.2025 – 12.2025

Заказная разработка под байера, работал один. Инструменты для закупок на Taobao и Pinduoduo с доставкой в РФ через карго.

- Разработал локальный прокси-сервис на FastAPI, который через Claude API генерирует товарные описания для таможенных документов в реальном времени.
- Спроектировал LLM-пайплайн со structured output для сборки сопроводительной документации.
- Внедрил автоматическую оценку качества по схеме LLM-as-a-judge: вторая модель проверяет результат, спорные случаи уходят человеку на ручную проверку.
- Написал клиентские скрипты на JavaScript (Tampermonkey), которые встраивают API в веб-интерфейсы китайских маркетплейсов.
- Сократил время обработки одной позиции с ~1,5 минуты до ~20 секунд. На партии из ~700 позиций (30 отправлений) это около 13 часов ручного ввода.

Python, FastAPI, JavaScript (Tampermonkey), Claude API, REST API, structured output, LLM-as-a-judge

Python / AI Engineer · 汉语中心 — платформа для изучения китайского 2024 – н. в.

Собственный проект, веб-сервис и AI-инструменты с нуля, работает в продакшене.

- Начал на Flask, перевёл на Django/DRF ради масштабирования: 8 Django-модулей, ~350 коммитов.
- Разработал MCP-сервер на 38 инструментов (колоды, уроки, расписание, прогресс) и встроил его в Django через Streamable HTTP / JSON-RPC: LLM-репетитор на Claude управляет данными ученика прямо из чата.
- Реализовал алгоритм интервального повторения SM-2: колоды, расчёт времени возврата карточек, аналитика прогресса.
- Настроил OAuth 2.1 (PKCE, динамическая регистрация клиентов): репетитор подключается без передачи паролей.
- Сделал REST API с документацией OpenAPI и деплой на Amvera.
- Разрабатываю LLM eval, чтобы измерять качество ответов репетитора.

Python, Django, DRF, Flask, Claude API, MCP, JSON-RPC, OAuth 2.1 (PKCE), OpenAPI, SM-2, Amvera

Data Analyst / ETL / Junior ML · Самолёт Плюс, Ульяновск 03.2023 – 08.2023

Стажировка, аналитика сделок сети агентств недвижимости.

- Разработал витрины данных на SQL (PostgreSQL) для клиентской аналитики: активность, конверсии, retention, воронки.
- Построил ETL-процессы на PySpark и Python: свёл данные из разных источников в датасеты для аналитики и ML.
- Проводил A/B-тесты: считал метрики, сравнивал группы, объяснял результаты команде.

Python, SQL, Pandas, NumPy, PostgreSQL, PySpark, ETL

ПРОЕКТЫ

Детекция объектов на аэроснимках 2024 – 2025

- Обучил и сравнил модели YOLOv5 и YOLOv8 по метрикам на валидационной выборке.

Python, PyTorch, Ultralytics YOLO

ОБРАЗОВАНИЕ

Финансовый университет при Правительстве РФ · Москва 2023 – 2027

Бакалавриат, 01.03.02 «Прикладная математика и информатика», профиль «Прикладное машинное обучение». Очная форма.